Radarbasierte Detektion epileptischer Anfälle mittels Deep Learning

Master-Abschlussarbeit - Kolloquium

Felix Richter

Betreuer: Prof. Dr. Jörn Schneider

Hamburg, 16.10.2025

Informatik
Fernstudium
HOCHSCHULE TRIER

Überblick

1. Aufgabenstellung
2. Ausgangsdaten
3. Statistische Auswertung I.
4. Statistische Auswertung II. (Auffälligkeiten)
5. Separierbarkeit der Daten
6. Bewegungsmuster
7. Ablauf Datenvorverarbeitung
8. Skripte und Ablauf
9. Validierung und Evaluation Modelle mit 3D-Faltung ohne Trennung
10. Validierung und Evaluation Modelle mit 3D-Faltung mit Trennung nach Anfällen oder Patienten
11. Modellarchitektur mit LSTM
12. Training, Ergebnisse, Modell mit LSTM
13. Modellarchitektur mit Attention
14. Training, Ergebnisse, Modell mit Attention
15. Ergebnisse
16. Ausblick – weitere Ansätze

Aufgabenstellung

Ziel der vorliegenden Arbeit ist es, mittels eines entsprechend trainierten neuronalen Netzes epileptische Anfälle in Radaraufzeichnung zu erkennen.

Vorgehen

1. Datenanalyse
2. Festlegen der Zielgrößen
3. Datenvorverarbeitung
4. Modelldesign
5. Training, Optimierung, Tuning, Augmentation
6. Evaluation
7. Visualisierung und Dokumentation

Ausgangsdaten

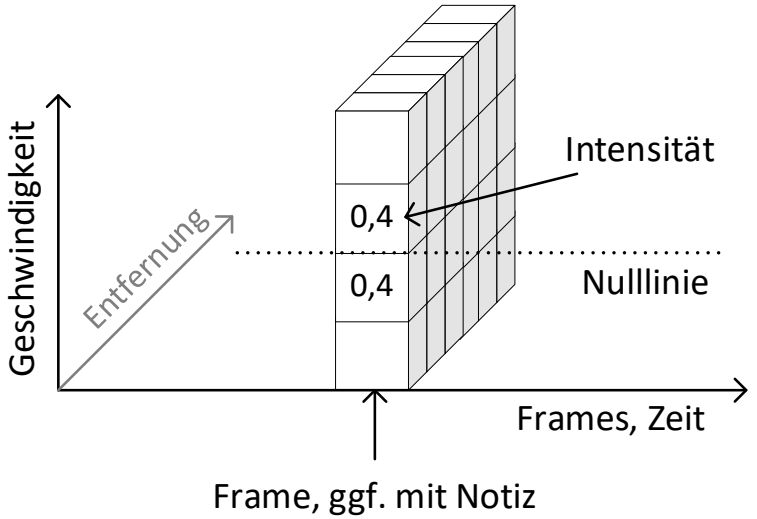
Radardaten
Dreidimensionales Array

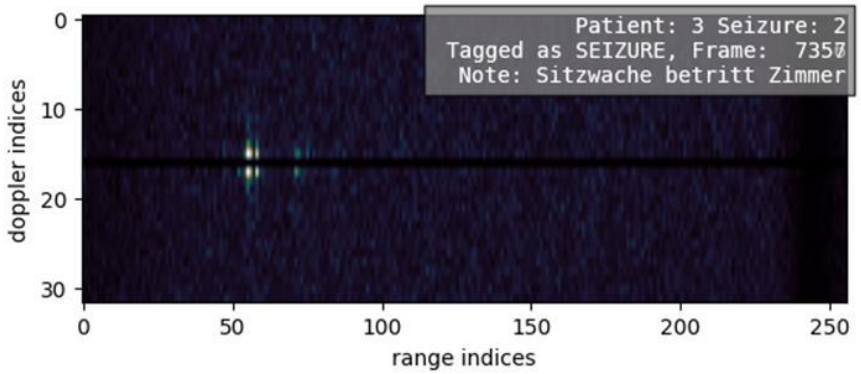
Achsen:
1. Zeit (40 Frames pro Sekunde)
2. Geschwindigkeit (0,16 m/s je Index)
3. Entfernung (4,41 cm je Index)

Ausgangsgröße:
1. Ca. 20.000 Frames je Aufzeichnung
2. 32 Indizes für die Geschwindigkeit
3. 256 Indizes für die Entfernung

Wert:
Intensität des Radarsignals als Float 32

Nulllinie:
eigener Index





Statistische Auswertung einer Aufzeichnung I.

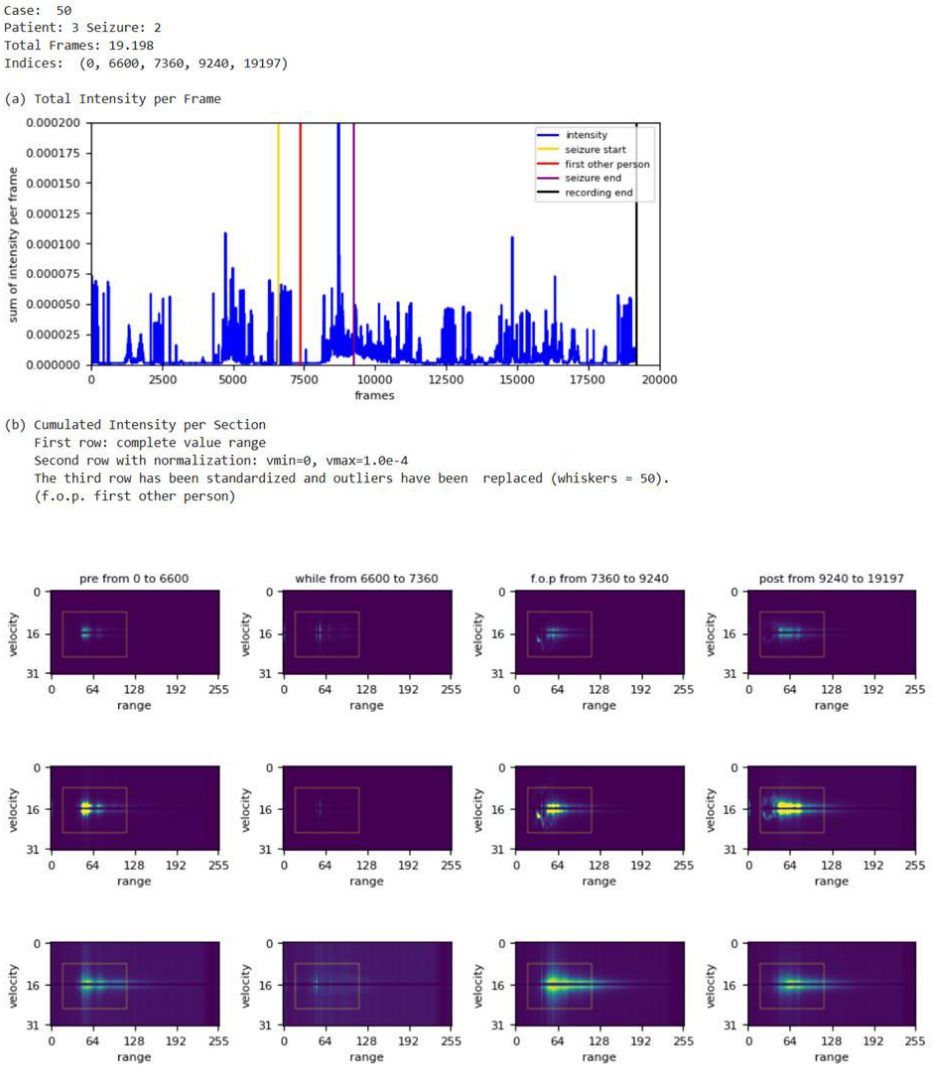
Abb. (a) Gesamtstärke je Frame

– Addition sämtlicher Intensitäten eines Frames (blau)

Abb. (b) Intensität je Sektion

– Addition sämtlicher Intensitäten einer Sektion je Bin

– dunkler Rahmen: als Bereich mit relevanten Daten erachtet



Statistische Auswertung einer Aufzeichnung II.

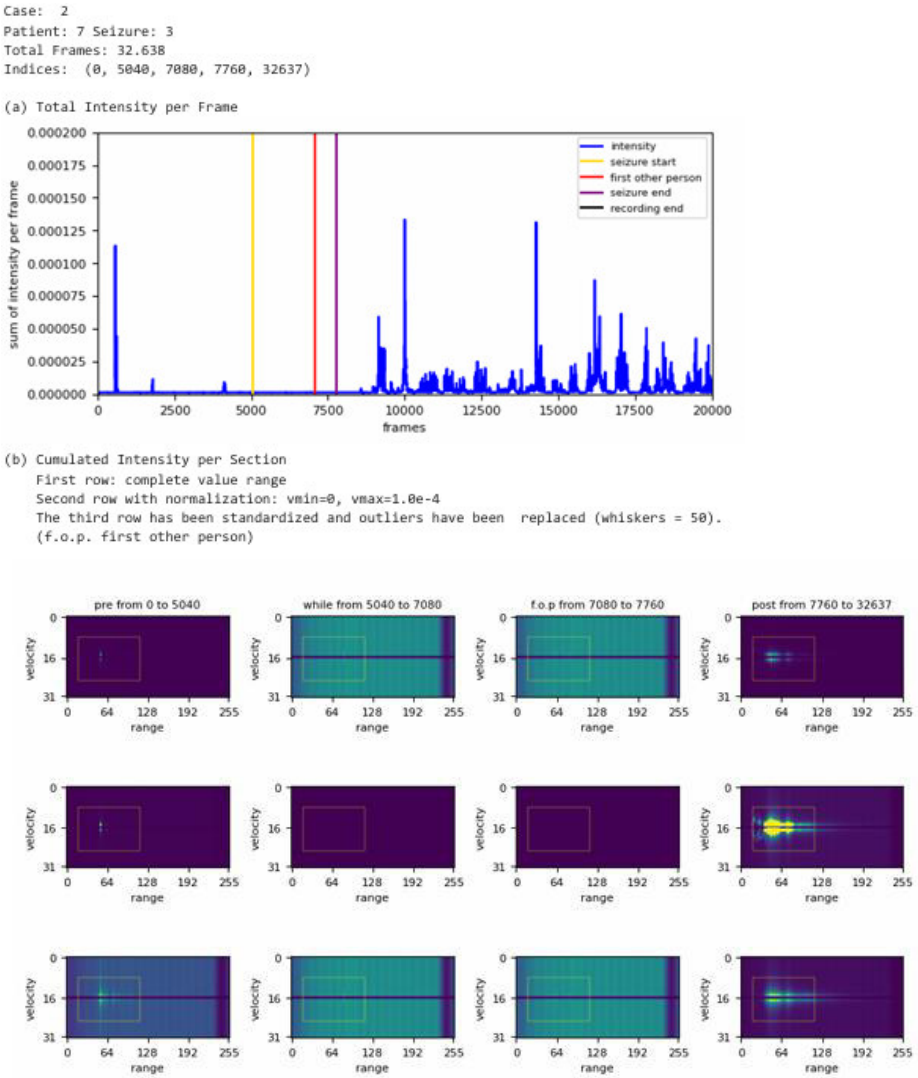
Auffälligkeiten

1. Anfall

– Eindruck: keine Daten (Spalte 2 und 3)

2. Standardisierung und Ersetzen von Ausreißern vor dem Anfall

– Eindruck: Rauschen entsteht (Spalte 1, Zeile 3)

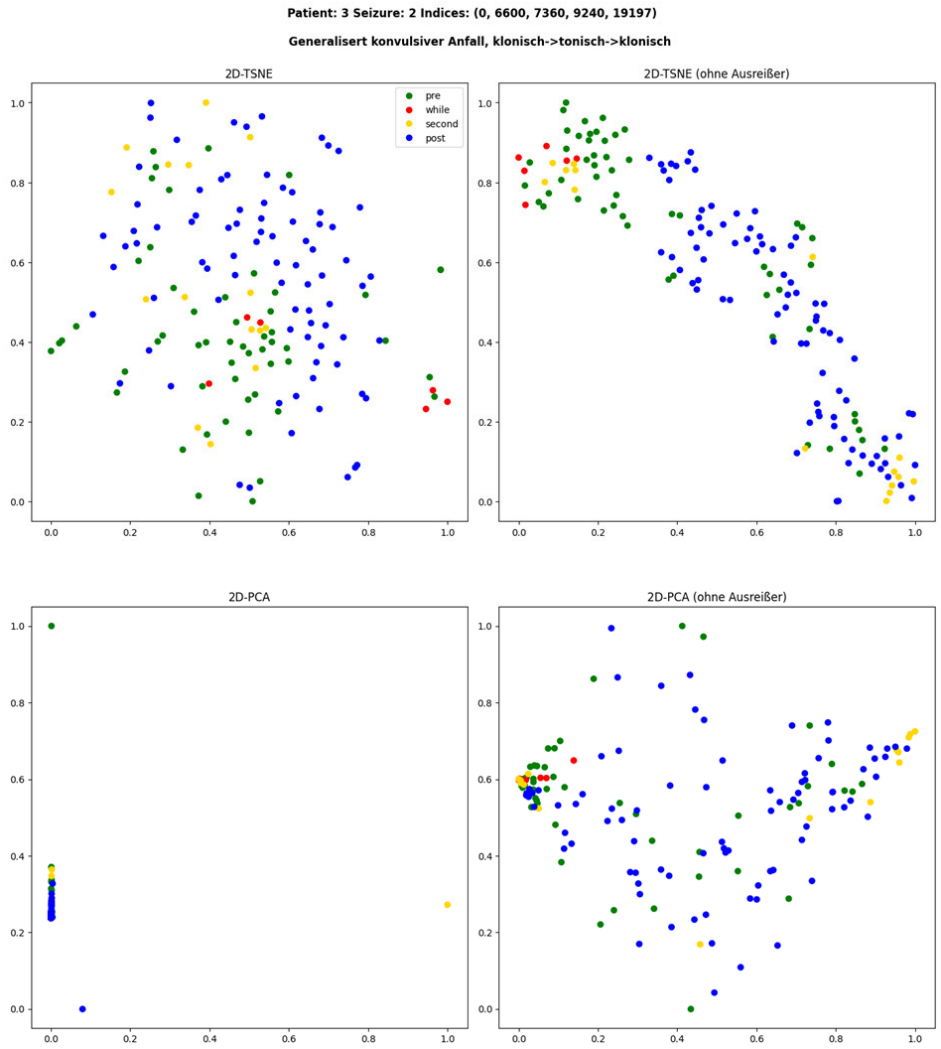


Separierbarkeit der Daten TSNE und PCA

Entfernung von Ausreißern mittels ‚Box-Plot', Länge der Antennen gleich 0,7 des Interquartilsabstandes

Auffälligkeiten

1. TSNE
   - Entfernen von Ausreißern spielt eine wesentliche Rolle
   - Separierbarkeit erkennbar
2. PCE
   - Entfernen von Ausreißern spielt eine wesentliche Rolle
   - Keine Separierbarkeit erkennbar



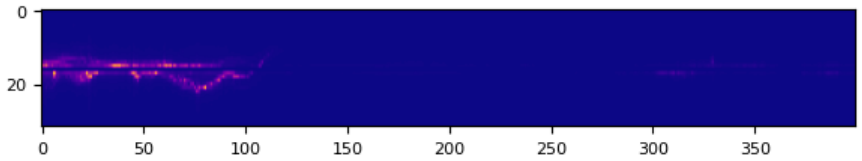
Bewegungsmuster

- x-Achse: Frames 8.000 bis 8.400 (ca. 10 Sekunden)
- y-Achse: Geschwindigkeit
- Entfernung je Frame und Geschwindigkeitsindex saldiert

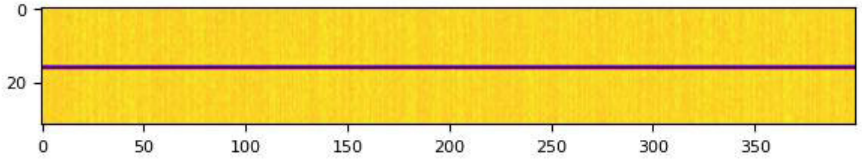
(a) Bewegungsmuster bis Frame 100 (während eines Anfalls, nach Auftreten einer weiteren Person)
(b) kein Bewegungsmuster (nach Auftreten einer weiteren Person, nach einem Anfall)
(c) einzelne Radarwerte (nach Auftreten einer weiteren Person, nach einem Anfall)

Indiz, dass größere Bereiche keine Muster enthalten

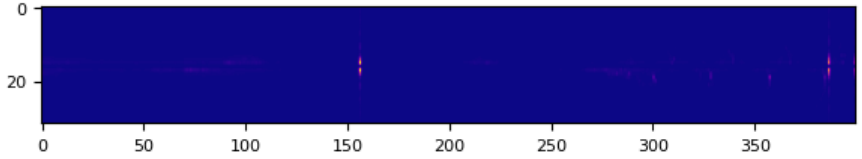
(a) Patient: 7 Seizure: 2
Total Frames: 19.678
Indices: (0, 4.960, 5.640, 8.520, 19.677)



(b) Patient: 7 Seizure: 3
Total Frames: 32.638
Indices: (0, 5.040, 7.080, 7.760, 32.637)

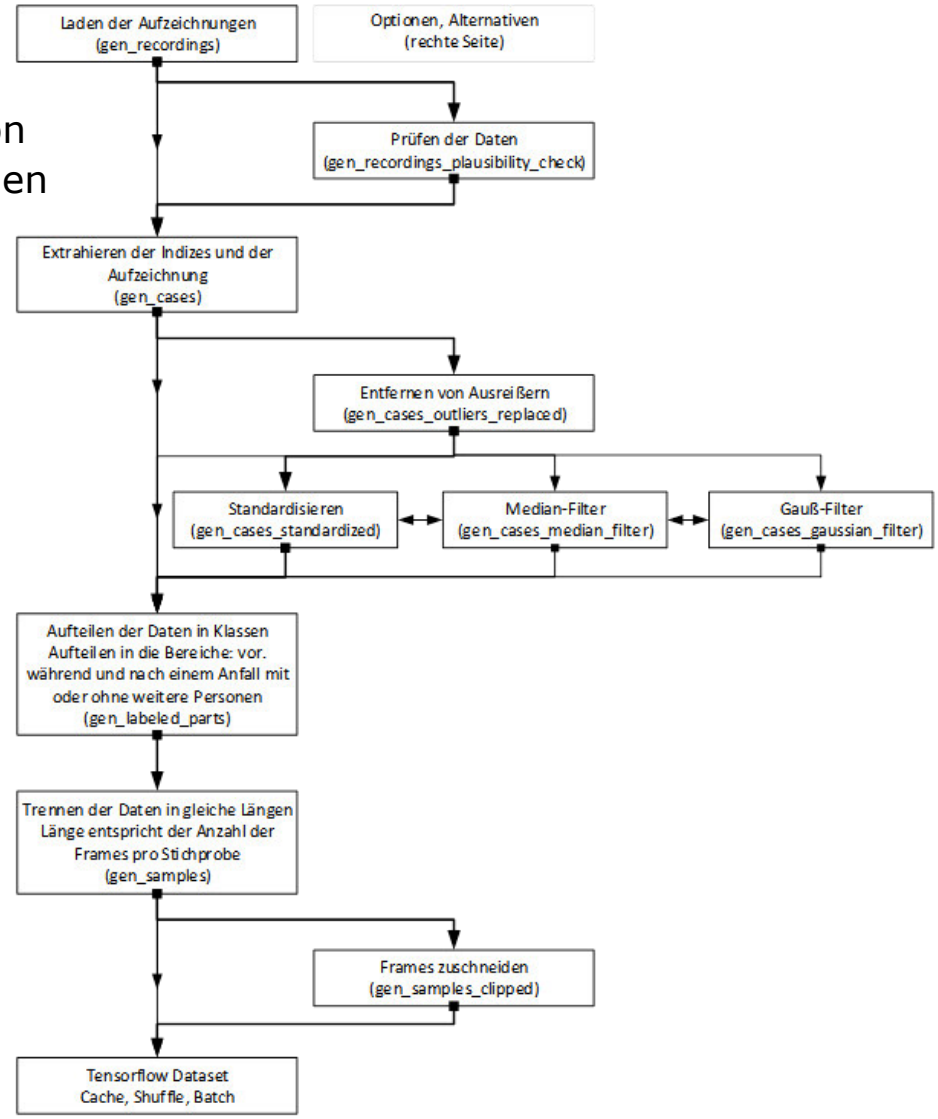


(c) Patient: 2 Seizure: 7
Total Frames: 19.198
Indices: (0, 6.600, 7.320, 7.400, 19.197)



Ablauf Datenvorverarbeitung

1. Laden der Daten und optionale Selektion von Anfallsarten, Patienten sowie Anfällen
2. Prüfen der Daten auf Plausibilität
3. Extrahieren der Indizes und Auslesen der Radardaten
4. Ersetzen von Ausreißern
5. Standardisierung der Daten
6. Median-Filter
7. Gauß-Filter
8. Aufteilen der Daten in Klassen
9. Trennen der Daten in gleiche Längen, Anzahl der Frames pro Stichprobe
10. Zuschneiden der Frames auf einen relevanten Datenausschnitt



Skripte und Ablauf

Skripte:

1. Modell
2. Hintergrund
3. Augmentation einschließlich Balancierung
4. Tunen
5. Visualisierung
6. Metriken und Callbacks

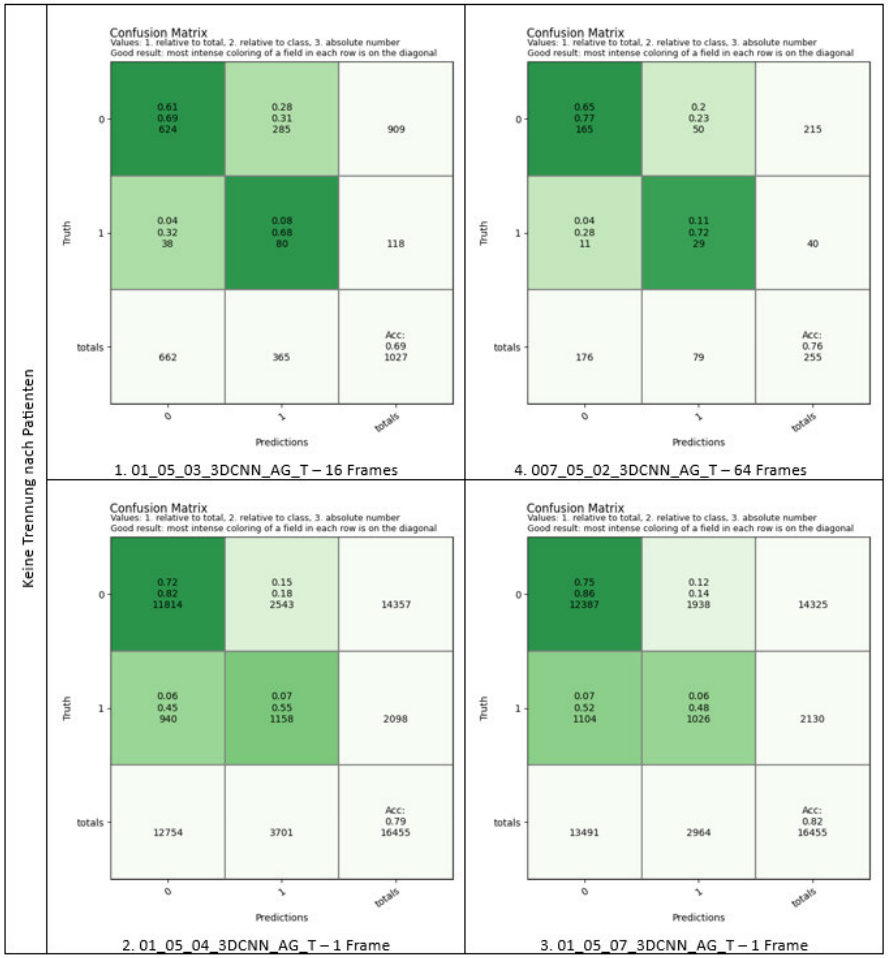
Ablauf in vier Schritten:

1. Laden, Aufbereiten und Aufteilen der Daten
2. Generieren des Modells, Training und Tuning
3. Evaluation
4. Speichern des Modells, der wichtigsten Parameter (Daten, Modell, Training, Tuning) und der Grafiken

Validierung und Evaluation Modelle mit 3D-Faltung

ohne Trennung

Nr.	Modell	Train. Param	Schichten	Acc.	Klasse	F2-Score	Fl. Neg.	Pos.
1	01_05_03_3DCNN_AG_T	872.834	30	0,685	0	0,717	1.159	3.589
					1*	0,513	150	521
2	01_05_04_3DCNN_AG_T	119.522	25	0,788	0	0,839	10.301	57.250
					1*	0,488	3.750	8.571
3	01_05_07_3DCNN_AG_T	127.778	28	0,815	0	0,871	8.053	57.354
					1*	0,439	4.435	8.467
4	007_05_02_3DCNN_AG_T	871.778	28	0,761	0	0,801	203	889
					1*	0,562	40	133

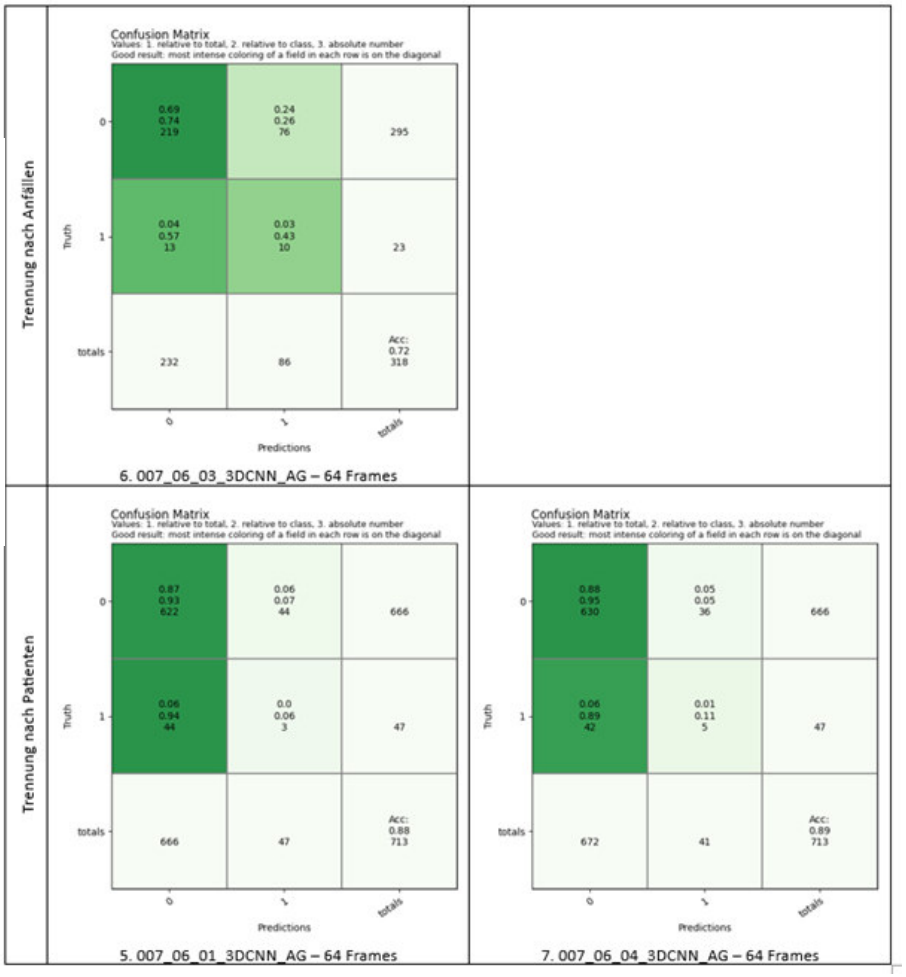


Validierung und Evaluation Modelle mit 3D-Faltung

mit Trennung nach Anfällen oder Patienten

Nr. 5 bis 7

Nr.	Modell	Train. Param	Schichten	Acc.	Klasse	F2-Score	Fl. Neg.	Pos.
1	01_05_03_3DCNN_AG_T	872.834	30	0,685	0	0,717	1.159	3.589
					1*	0,513	150	521
2	01_05_04_3DCNN_AG_T	119.522	25	0,788	0	0,839	10.301	57.250
					1*	0,488	3.750	8.571
3	01_05_07_3DCNN_AG_T	127.778	28	0,815	0	0,871	8.053	57.354
					1*	0,439	4.435	8.467
4	007_05_02_3DCNN_AG_T	871.778	28	0,761	0	0,801	203	889
					1*	0,562	40	133
5	007_06_01_3DCNN_AG	215.018	20	0,868	0	0,922	74	904
					1*	0,304	56	82
6	007_06_03_3DCNN_AG	215.018	20	0,764	0	0,811	126	607
					1*	0,530	56	135
7	007_06_04_3DCNN_AG	215.018	20	0,947	0	0,925	70	904
					1*	0,284	58	82
								*Anfall



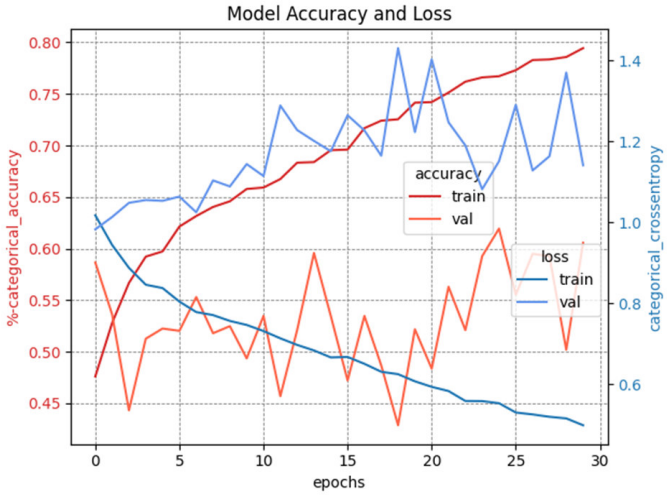
Modellarchitektur mit LSTM

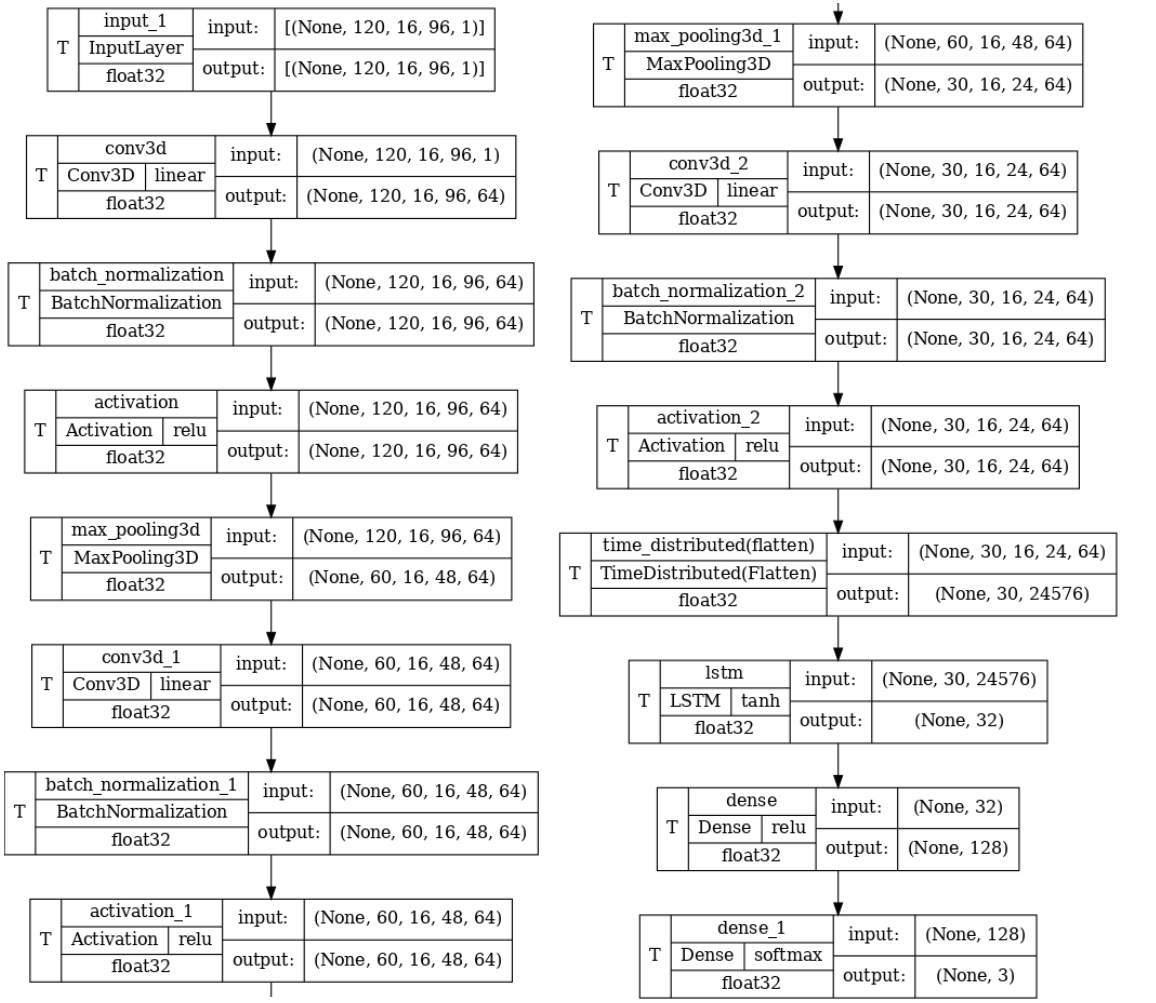
Training

- kontinuierliche Verbesserung

Validierung

- Genauigkeit schwankt zwischen 40 und 65 %
- Verlust schwankt zwischen circa 1,0 und 1,4, mit leicht steigender Tendenz und wachsender Schwankungsbreite



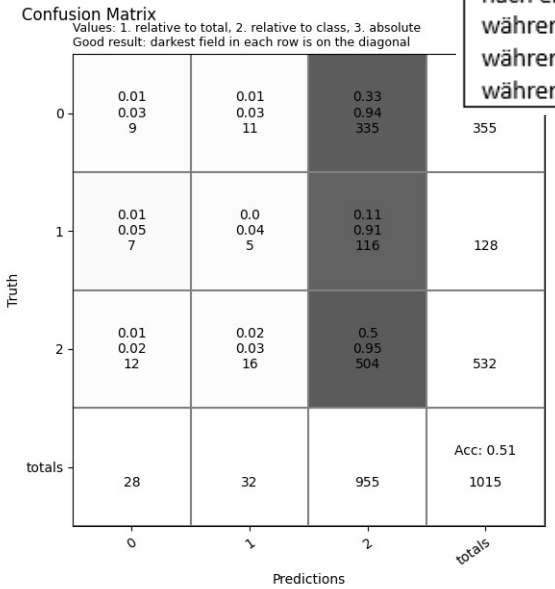


Training, Ergebnisse, Modell mit LSTM

	Modell	Train. Param	Schichten	Acc.	Klasse	F2-Score	Fl. Neg.	Pos.
1	026_10_01_3DConv_LSTM_AG	3.378.051	16	0,529	0	0,811	53	482
					1*	0,384	94	165
					2	0,492	370	664

Klassen 026_10_01_3DConv_LSTM_AG Anzahl: 7	**Frames** 120	**Anfälle** all	**Phase**	**Patient**	**Datensätze**
			Training	4, 5, 6, 8	4.823
			Validierung	2, 9	1.311
			Test	3, 7	1.015
			Gesamt		7.149

Klassenzuordnung	**Label**	**Train**	**Val**	**Indizes**
vor einem Anfall	0	2.373	2.373	(01)
während eines Anfalls	1	342	342	(12)
während eines Anfalls mit weiteren Personen	1	470	470	(23)
nach einem Anfall	2	2.782	2.782	(34)
während eines Anfalls ohne weitere Personen	1	205	205	(13)
während eines Anfalls ohne weitere Personen ohne Ende des Anfalls	1	550	550	(14)
während eines Anfalls mit weiteren Personen ohne Ende des Anfalls	1	427	427	(24)



Ergebnis:

Validierung

- Gesamtgenauigkeit über 52 %
- F2-Score für Anfälle gering, mehr als 50% falsch negativ

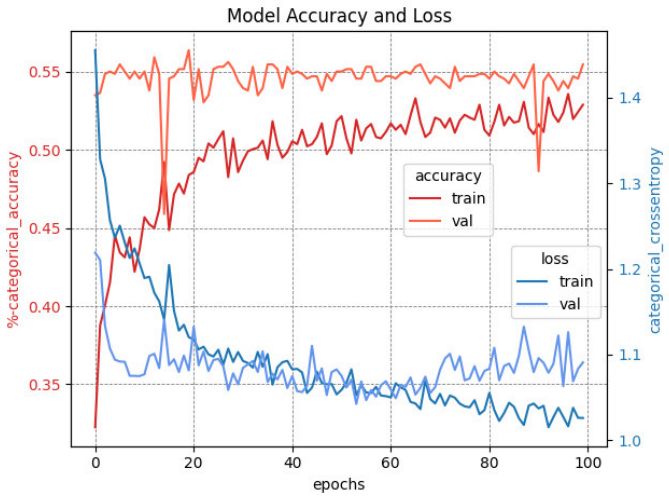
Evaluation (Konfusionsmatrix)

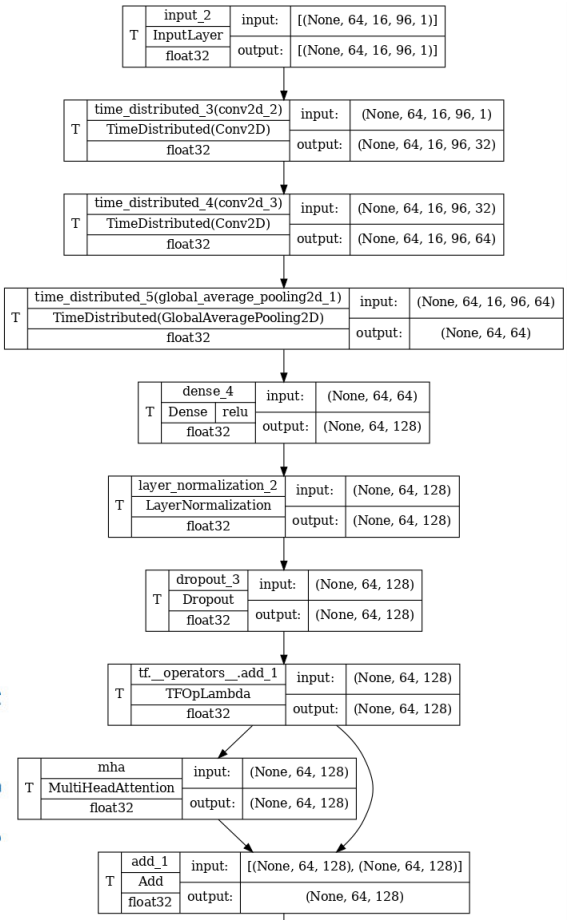
- Zu jeweils über 90 % werden die Stichproben der zahlenmäßig größten Klasse zugeordnet.

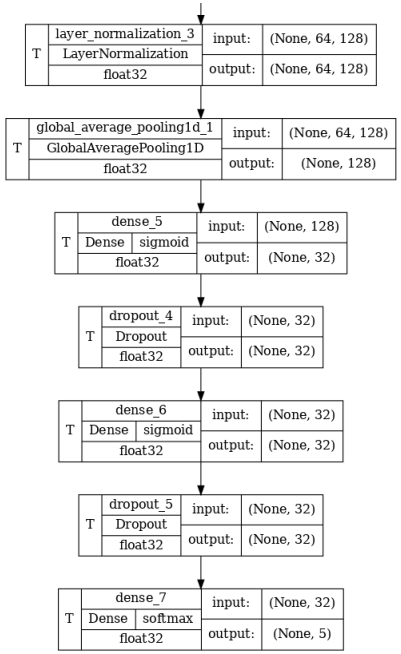
Modellarchitektur mit Aufmerksamkeit

Training
- kontinuierliche Verbesserung

Validierung
- Genauigkeit bei circa 55 %, eher gleichbleibend
- Verlust schwankt bei circa 1,1, eher gleichbleibend



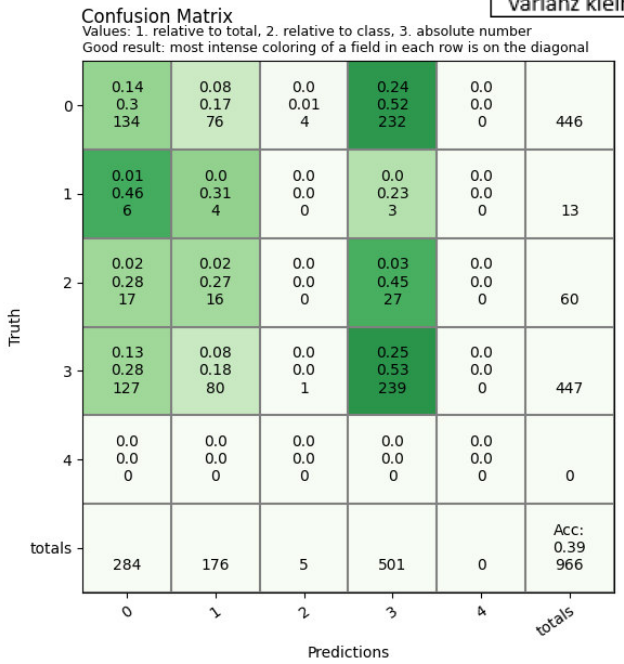




Training, Ergebnisse, Modell mit Aufmerksamkeit

Klassen	Frames	Anfälle	Phase	Patient	Datensätze
Anzahl: 4	64	*konvulsiv*	Training	9	1.286
			Validierung	6	658
			Test	3	966
			Gesamt		2.910

Klassenzuordnung	Label	Train	Val	Indizes
vor einem Anfall	0	488	206	(01)
während eines Anfalls	1	75	71	(12)
während eines Anfalls mit weiteren Personen	2	178	204	(23)
nach einem Anfall	3	545	177	(34)
während eines Anfalls ohne weitere Personen	-	0	0	(13)
während eines Anfalls ohne weitere Personen ohne Ende des Anfalls	-	0	0	(14)
während eines Anfalls mit weiteren Personen ohne Ende des Anfalls	-	0	0	(24)
Varianz kleiner als Schwellwert	4	0	0	



	Modell	Train. Param	Schichten	Acc.	Klasse	F2-Score	Fl. Neg.	Pos.
4	05_05_09_TD_2DConv_PE_At_AG_T	99.045	17	0,427	0	0,807	20	206
					1*	0,000	71	71
					2*	0,000	204	204
					3	0,863	0	177
					4	0,000	0	0

Ergebnis:

Validierung

- Gesamtgenauigkeit über 42 %
- F2-Score für Anfälle gleich 0

Evaluation (Konfusionsmatrix)

- Zum größten Teil werden die Stichproben der zahlenmäßig größten Klasse zugeordnet.

Ergebnisse

1. Aufteilung der Daten (Patient/Anfall in Training, Validierung, Test) hat wesentlichen Einfluss auf das Ergebnis
2. Datensätze enthalten entsprechend ihrer Klasse nicht ausreichend unterscheidbare Bewegungsmuster (eventuell zeigt ein Patient während eines Anfalls kurz auch normale Muster, die jedoch die Stichprobe von wenigen Frames ausmachen)
3. Wenige Frames je Stichprobe können ausreichend sein und erhöhen die Anzahl der zur Verfügung stehenden Datensätze
4. Umfangreiche Vorverarbeitung erhöht die Anzahl der Parameter und erschwert so die Lösungssuche
5. Modelle mit Dreiteilung in Merkmalsextraktion (2D- und 3D-Faltung), Zeitkomponente (LSTM und Transformer) und Klassifizierung (Dense) wiesen keine Generalisierung auf

Ausblick – weitere Ansätze

1. Weitere Datenanalysen
   a) Untersuchung der Daten auf verwendbare Sequenzen
   b) Untersuchung der Daten auf für Anfälle typische Bewegungsmuster
   c) Vergleich von Anfallsarten nach ihren jeweils typischen Mustern
2. Verwendung der circa 50 weiteren Aufzeichnungen, die nicht als Entfernungs-Doppler-Diagramm vorliegen
3. Weitere Modelle
   a) Frameweise gelabelte Daten
      - Ab einer bestimmten Anzahl positiver Frames wird die Sequenz positiv klassifiziert
   b) Transferlearning
   c) Verwendung der Radarrohdaten als Eingangsdaten für ein neuronales Netz
   d) Modell mit mehreren Ausgaben
      - Sequenz enthält Bewegungsmuster
      - Anzahl Personen
      - Klassifizierung

Informatik
Fernstudium

HOCHSCHULE TRIER